

Deteksi Penyakit Tuberculosis Berdasarkan Citra X-Ray

First N. Bangun, *Fellow, IEEE*, Second I. Amal, Third M.A. Muflih, and fourth F. F. A. Hawe
Master Ilmu Komputer dan Elektronika, Universitas Gadjah Mada, Yogyakarta, Indonesia

1

Abstract—Tuberculosis (TB) merupakan penyakit infeksi paru dengan angka kasus tinggi secara global sehingga diperlukan sistem deteksi dini yang akurat dan efisien. Penelitian ini mengembangkan metode klasifikasi TB berbasis citra X-ray dada (CXR) menggunakan tahapan *preprocessing*, segmentasi paru, ekstraksi fitur tekstur, dan klasifikasi berbasis pembelajaran mesin. *Enhancement* citra dilakukan menggunakan CLAHE dan *mean shift filtering*, sedangkan segmentasi ROI paru diperoleh melalui *thresholding*, kontur, dan operasi morfologi. Fitur tekstur diekstraksi menggunakan *Gray Level Co-occurrence Matrix* (GLCM) dan *Local Binary Pattern* (LBP) untuk menggambarkan struktur dan pola lokal pada jaringan paru. Tiga algoritma pembelajaran mesin Random Forest, Support Vector Machine (SVM), dan K-Nearest Neighbors (KNN) digunakan untuk melakukan klasifikasi dua kelas (normal dan TB). Hasil evaluasi menunjukkan bahwa SVM dengan normalisasi memberikan performa terbaik dengan akurasi 0.812, diikuti Random Forest dengan 0.804, dan KNN dengan 0.729. Temuan ini menunjukkan bahwa kombinasi *preprocessing*, segmentasi paru yang tepat, serta fitur tekstur GLCM–LBP mampu meningkatkan efektivitas model pembelajaran mesin dalam mendeteksi TB dari citra CXR. Sistem ini berpotensi digunakan sebagai alat bantu diagnosis untuk mendukung deteksi dini TB di fasilitas kesehatan.

Index Terms—Tuberculosis, Klasifikasi, Pembelajaran Mesin, Pengolahan Citra Digital

I. PENDAHULUAN

Tuberculosis (TB) merupakan penyakit infeksi saluran pernapasan yang disebabkan oleh *Mycobacterium tuberculosis* dan tetap menjadi tantangan besar kesehatan masyarakat global, dengan jutaan kasus baru dan lebih dari satu juta kematian setiap tahun, terutama di negara berpenghasilan rendah dan menengah seperti Indonesia. Meskipun berbagai upaya dilakukan dalam kerangka End TB Strategy, keberhasilan pengendalian TB sangat bergantung pada deteksi dini dan akurat agar penularan dapat segera diputus dan pengobatan dimulai sejak awal.[1][2][3]

Secara klinis, diagnosis TB masih mengandalkan pemeriksaan mikroskopis dahak, kultur, uji molekuler cepat, dan interpretasi chest X-ray (CXR) oleh tenaga ahli, yang masing-masing memiliki keterbatasan terkait sensitivitas, waktu pemeriksaan, kebutuhan fasilitas, serta ketersediaan sumber daya manusia terlatih. CXR sendiri tergolong modalitas yang murah, non-invasif, dan luas tersedia, sehingga banyak dimanfaatkan sebagai alat skrining awal; namun interpretasi visualnya rentan terhadap variabilitas antar-pembaca, bias subjektif, dan beban kerja tinggi yang

dapat menurunkan konsistensi diagnosis.[4][5][6]

Perkembangan computer vision dan kecerdasan buatan mendorong pemanfaatan sistem computer-aided diagnosis (CAD) untuk membantu deteksi kelainan paru pada CXR secara lebih objektif dan konsisten, khususnya di fasilitas kesehatan primer dengan sumber daya terbatas. Dalam konteks tersebut, model pembelajaran mesin (machine learning/ML) berbasis fitur citra menawarkan alternatif yang relatif ringan dan lebih mudah dijelaskan dibandingkan model deep learning, sehingga berpotensi lebih mudah diadopsi dalam praktik klinis.[5][6][7]

Penelitian ini mengusulkan sistem klasifikasi TB berbasis citra CXR yang terdiri dari beberapa tahapan utama, yaitu pra-pemrosesan, segmentasi paru, ekstraksi fitur, dan klasifikasi. Pada tahap pra-pemrosesan, citra dikonversi ke grayscale dan ditingkatkan kontrasnya menggunakan Contrast Limited Adaptive Histogram Equalization (CLAHE) untuk memperjelas struktur paru yang relevan. Tahap segmentasi dilakukan dengan kombinasi *thresholding* adaptif, median filtering, dan operasi morfologi guna memperoleh mask paru yang utuh dan meminimalkan pengaruh struktur non-paru. Dari wilayah paru tersegmentasi kemudian di ekstraksi fitur tekstur menggunakan Gray Level Co-occurrence Matrix (GLCM) untuk merepresentasikan pola heterogenitas dan distribusi intensitas yang berkaitan dengan lesi TB, yang selanjutnya digunakan sebagai masukan bagi model klasifikasi biner (normal vs TB) berbasis algoritma ML. Kinerja sistem dievaluasi menggunakan metrik akurasi, presisi, recall, dan F1-score dengan tujuan menghasilkan model yang andal, relatif transparan, dan relevan secara klinis untuk mendukung diagnosis dini TB di pelayanan kesehatan primer

II. PENELITIAN TERKAIT

Pemodelan berbasis CNN untuk deteksi Tuberculosis (TB) dari citra rontgen dada (CXR) terus berkembang. Cuenca-Dominguez dkk. (2024) mengevaluasi arsitektur ResNet 50 untuk deteksi dini TB pada CXR [8], menunjukkan potensi jaringan residual dalam menangkap pola radiologis yang relevan. Gupta dkk. (2025) menilai VGG16 dan VGG19 pada tugas serupa [9], menegaskan bahwa keluarga VGG masih menjadi baseline yang kuat untuk klasifikasi CXR. Selain itu, Cao dkk. (2021) menerapkan DenseNet untuk klasifikasi TB [11], dengan pemanfaatan koneksi dens yang membantu aliran gradien dan reuse fitur. Secara umum, pendekatan CNN end-to-end seperti ini efektif mengekstraksi representasi tingkat tinggi, namun cenderung memerlukan data latih besar dan sumber daya komputasi yang lebih tinggi, serta

menghadapi tantangan interpretabilitas model.

Di sisi lain, pendekatan hybrid memadukan fitur buatan (handcrafted) dengan deep features untuk menyeimbangkan akurasi dan interpretabilitas. Fati dkk. (2022) mengusulkan teknik deep-hybrid berbasis feature fusion yang menggabungkan fitur tekstur seperti GLCM dengan representasi dari jaringan dalam (misalnya ResNet), kemudian diklasifikasikan menggunakan ANN [10]. Ahmed dkk. (2023) menerapkan skema multi-teknik untuk membedakan pneumonia dan TB dengan memadukan LBP, DWT, dan GLCM bersama VGG16 serta ResNet18 [12]. Laporan-laporan ini menunjukkan bahwa fusi fitur dapat meningkatkan ketahanan model pada variasi kualitas citra dan ukuran data yang terbatas, sekaligus memberikan jejak fitur yang lebih mudah ditafsirkan dibanding CNN murni. Namun, kinerja pendekatan hybrid sangat dipengaruhi oleh konsistensi pra-pemrosesan dan kualitas segmentasi area paru (ROI) tempat fitur diekstraksi.

Berdasarkan studi-studi yang ditinjau, masih terdapat ruang perbaikan pada tahap peningkatan kualitas citra dan isolasi ROI paru sebelum ekstraksi fitur. Pada sebagian pekerjaan, segmentasi paru eksplisit dan peningkatan kontras yang sistematis (misalnya CLAHE) belum selalu menjadi komponen inti pipeline, padahal langkah-langkah ini berpotensi meningkatkan relevansi fitur tekstur yang diekstraksi. Dengan latar tersebut, penelitian ini memposisikan diri sebagai pipeline yang ringan dan lebih interpretatif: pra-pemrosesan (grayscale, CLAHE), segmentasi paru berbasis thresholding, median blur, dan operasi morfologi untuk memperoleh ROI yang bersih, ekstraksi fitur tekstur menggunakan GLCM pada area paru, lalu klasifikasi menggunakan model pembelajaran mesin. Pendekatan ini diharapkan menjaga efisiensi komputasi sekaligus mempertahankan akurasi kompetitif, serta mempermudah analisis dan penjelasan hasil melalui fitur tekstur yang terkait pola infeksi TB.

III. METODOLOGI

Penelitian ini mengembangkan sistem deteksi tuberkulosis pada citra CXR berbasis teknik pengolahan citra digital. Metodologi yang diterapkan mencakup tahap preprocessing citra serta pelatihan model machine learning menggunakan algoritma Random Forest, Support Vector Machine, dan k-Nearest Neighbors. Secara umum Alur penelitian ini dapat dilihat pada figur 1

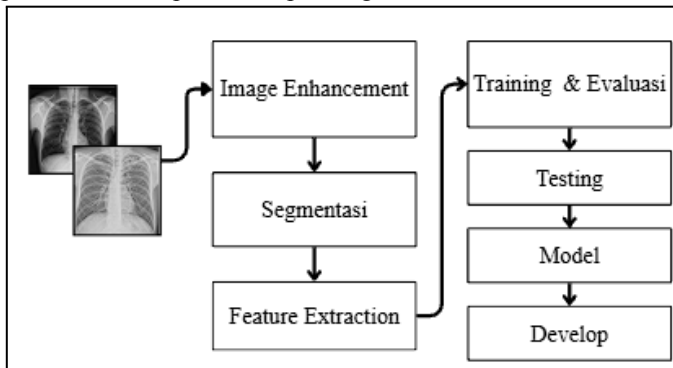


Fig 1. Alur penelitian

A. Dataset

Penelitian ini menggunakan dataset citra tuberkulosis dan normal dari Tuberculosis Chest X-rays yang didapatkan pada platform Kaggle[13]. Dataset ini berisi citra radiografi dada (*chest-X-Ray / CXR*) yang dibagi menjadi dua kelas utama yakni: citra paru normal dan citra paru dengan infeksi TB. Secara keseluruhan terdapat total 662 citra, dimana terdapat 326 citra paru normal dan 336 citra paru dengan infeksi TB. Contoh citra yang digunakan dalam penelitian ini dapat dilihat pada figure 2



Fig 2. Sampel dataset normal dan tuberkulosis

Dataset akan dibagi menjadi beberapa subset untuk keperluan *training*, *testing* dan *validasi* agar model klasifikasi dapat dievaluasi secara objektif. Dengan menggunakan dataset ini, penelitian diharapkan dapat mengembangkan sistem klasifikasi TB berbasis citra yang andal

B. Image Enhancement

Enhancement adalah tahap yang dilakukan setelah akuisisi data, di mana citra mentah diproses untuk meningkatkan kualitas visualnya agar fitur-fitur penting menjadi lebih jelas dan mudah dianalisis oleh model. Dalam penelitian ini, teknik enhancement yang digunakan fokus pada penyesuaian kualitas citra sesuai dengan yang dibutuhkan menggunakan metode *Contrast Limited Adaptive Histogram Equalization (CLAHE)* dan Mean Shift Filter untuk memastikan area terduga lesi TBC lebih menonjol dan dapat diproses secara optimal pada tahap segmentasi.

C. Segmentasi

Segmentasi digunakan untuk memisahkan object foreground dan background. segmentasi pada dataset x-ray dada untuk memisahkan object paru paru (foreground) dan objek lain dan latar belakang (background) dilakukan dengan berbasis kontur untuk mengekstraksi Region of Interest (ROI) paru-paru dari citra chest X-ray. Pendekatan ini dipilih dengan mempertimbangkan karakteristik anatomis paru-paru yang memiliki batas kurvatur tertutup yang konsisten secara spasial. Mekanisme ini bekerja dengan meminimalkan energi fungsional untuk mendeteksi batas objek berdasarkan gradien intensitas dan homogenitas wilayah, sehingga mampu memisahkan struktur paru dari elemen anatomis sekitarnya seperti jantung, mediastinum, dan tulang rusuk.

D. Operasi Morphologi

Operasi morfologi merupakan pendekatan dalam pengolahan citra yang memanfaatkan bentuk (*shape*) dan struktur objek pada citra. Operasi morfologi menggunakan *structuring element (SE)*, yaitu matriks kecil dengan bentuk tertentu yang berfungsi sebagai alat untuk modifikasi atau menganalisis struktur dalam citra. Secara umum tujuan operasi morfologi adalah untuk memperbaiki kualitas segmentasi,

mengurangi *noise*, dan menegaskan bentuk objek agar lebih mudah diidentifikasi pada proses selanjutnya.

Operasi morfologi yang digunakan pada penelitian ini adalah *opening*. Operasi morfologi *opening* merupakan kombinasi operasi erosi yang diikuti dengan operasi dilasi. Tujuan utama teknik ini adalah untuk: 1) Menghilangkan *noise* kecil tanpa mengubah bentuk objek. 2) Menghaluskan tepi objek. 3) Memisahkan objek yang berhimpitan. Hasil dari image preprocessing dapat dilihat pada Figure 2 berikut.




Fig 2. Hasil Image Segmentasi

E. Ekstraksi Fitur

Ekstraksi fitur adalah tahap penting dalam pengolahan citra digital. Ekstraksi fitur bertujuan untuk mengubah data citra mentah menjadi informasi numerik yang terstruktur dan dapat diproses oleh algoritma pembelajaran mesin. Dalam penelitian ini ekstraksi fitur membantu memfokuskan pada bagian penting dari citra yang membedakan antara kelas normal dan kelas terinfeksi TB.

Terdapat beberapa fitur yang digunakan pada penelitian ini diantaranya adalah: *Gray Level Co-occurrence Matrix* (GLCM) dan *Local Binary Pattern* (LBP).

Gray Level Co-occurrence Matrix (GLCM) adalah metode ekstraksi fitur yang banyak digunakan dalam pengolahan citra digital, terutama ketika ingin mengidentifikasi pola, struktur, dan tingkat kekasaran permukaan dari sebuah objek. GLCM menganalisis bagaimana pasangan nilai intensitas piksel muncul secara bersamaan pada jarak dan arah tertentu. Dengan kata lain, GLCM tidak hanya

melihat nilai piksel tunggal, tetapi hubungan antar piksel yang berdekatan.

GLCM mampu menangkap perubahan tekstur dengan menghitung hubungan piksel-piksel pada citra paru. Oleh karena itu, fitur yang dihasilkan informatif untuk membedakan citra paru normal dan citra paru dengan TB. Pada penelitian ini GLCM hanya menggunakan satu arah yakni 0° , terdapat berbagai fitur tekstur dari perhitungan menggunakan GLCM yang digunakan pada penelitian ini, diantaranya adalah: *contrast*, *correlation*, *energy*, *homogeneity*, dan *entropy*.

Local Binary Pattern (LBP) adalah metode ekstraksi fitur yang bekerja dengan cara membandingkan nilai intensitas suatu piksel dengan tetangganya. Hasil perbandingan membentuk pola biner delapan bit yang akan dikonversi menjadi nilai desimal. Nilai ini yang akan menjadi fitur tekstur pada area tersebut. LBP efektif untuk menangkap pola tekstur halus yang sering muncul pada jaringan paru. Selain itu LBP bersifat invarian terhadap perubahan pencahayaan lokal. Kombinasi LBP dan GLCM memberikan representasi tekstur yang lebih komprehensif. LBP mampu menggambarkan pola lokal, sedangkan GLCM mampu menangkap hubungan spasial antar-piksel.

F. Training

Dalam penelitian ini digunakan beberapa algoritma pembelajaran mesin untuk melakukan klasifikasi antara citra paru normal dan citra paru yang terinfeksi Tuberkulosis (TB). Setiap algoritma memiliki karakteristik, kelebihan, serta cara kerja yang berbeda dalam mempelajari pola dari fitur-fitur yang telah diekstraksi, seperti GLCM dan LBP. Tiga algoritma yang digunakan adalah Random Forest, Support Vector Machine (SVM), dan K-Nearest Neighbor (KNN).

Random Forest (RF)

Random Forest adalah algoritma machine learning yang termasuk dalam kategori Ensemble Learning. Random Forest bekerja dengan cara membangun banyak Decision Tree pada saat pelatihan.

Support Vector Machine (SVM)

Metode Support Vector Machine (SVM) digunakan dalam penelitian ini sebagai algoritma pembelajaran mesin untuk melakukan klasifikasi citra sinar-X dada (CXR) menjadi dua kelas: Tuberkulosis (TB) positif dan normal. SVM adalah algoritma pengawasan (supervised learning) yang bertujuan menemukan hyperplane optimal yang memaksimalkan margin pemisah antara kelas-kelas data yang berbeda.

K-Nearest Neighbors (KNN)

k-Nearest Neighbors (k-NN) adalah metode klasifikasi berbasis kemiripan yang bekerja dengan cara membandingkan citra X-Ray. Algoritma ini mencari sejumlah k terdekat di ruang fitur, lalu mengambil keputusan berdasarkan suara mayoritas dari tetangga tersebut; jika sebagian besar tetangga terdekat adalah citra TBC, maka citra baru itu pun didiagnosis sebagai TBC. Pendekatan ini efektif karena memanfaatkan pola lokal, di mana citra dengan fitur visual yang mirip diasumsikan memiliki kondisi medis yang sama.

G. Evaluasi

Pada tahap evaluasi, dilakukan pengukuran kinerja model klasifikasi untuk menilai sejauh mana algoritma pembelajaran mesin mampu membedakan citra paru normal dan citra paru terinfeksi TB. Evaluasi dilakukan menggunakan beberapa metrik yang umum digunakan dalam sistem klasifikasi, yakni *accuracy*, *precision*, *recall*, *F1-Score*, dan *Confusion Matrix*. Evaluasi dilakukan menggunakan dataset *testing* yang merupakan subset dari dataset utama. Melalui proses evaluasi ini, performa setiap model dapat dianalisis secara kuantitatif sehingga dapat ditentukan model yang paling optimal untuk tugas klasifikasi citra paru. Hasil evaluasi juga digunakan sebagai dasar untuk melakukan penyetelan parameter (*hyperparameter tuning*) jika diperlukan guna meningkatkan akurasi dan generalisasi model.

IV. HASIL DAN PEMBAHASAN

Pada tahap evaluasi, tiga algoritma pembelajaran mesin digunakan untuk membedakan citra paru normal dan citra paru terinfeksi TB, yaitu Random Forest, Support Vector Machine (SVM), dan K-Nearest Neighbors (KNN). Evaluasi dilakukan menggunakan metrik meliputi *accuracy*, *precision*, *recall*, *f1-score*, serta analisis confusion matrix untuk memahami performa masing-masing model secara lebih komprehensif.

Random Forest memperoleh *accuracy* sebesar 0.8045. Berdasarkan confusion matrix pada figure 3, model mampu mengklasifikasikan 52 sampel kelas normal dengan benar dan 55 sampel kelas TB secara tepat. Nilai *precision* dan *recall* pada kedua kelas cukup seimbang, yaitu sekitar 0.79–0.83, dengan *f1-score* berada pada kisaran 0.80–0.81.

```

=== RANDOM FOREST ===
Accuracy: 0.8045112781954887

Confusion Matrix:
[[52 15]
 [11 55]]

Classification Report:

```

	precision	recall	f1-score	support
0	0.83	0.78	0.80	67
1	0.79	0.83	0.81	66
accuracy			0.80	133
macro avg	0.81	0.80	0.80	133
weighted avg	0.81	0.80	0.80	133

Fig 3. *Confusion matrix* model random forest

Hasil ini menunjukkan bahwa Random Forest memiliki performa yang stabil dalam membedakan pola tekstur paru normal dan paru dengan TB. Kemampuan model dalam menangani fitur yang banyak serta menangkap pola non-linear menjadi salah satu faktor yang mendukung performanya pada dataset ini.

SVM dengan normalisasi menunjukkan kinerja terbaik di antara seluruh model, dengan *accuracy* sebesar 0.8120. Model mampu mengklasifikasikan 48 sampel kelas normal dan 60 sampel kelas TB dengan benar. SVM

menunjukkan *precision* yang tinggi pada kelas normal (0.89), meskipun *recall*-nya lebih rendah (0.72). Sebaliknya, pada kelas TB, model menghasilkan *recall* tinggi (0.91), menunjukkan bahwa SVM sangat efektif dalam mendeteksi kasus TB meskipun *precision*-nya sedikit lebih rendah (0.76).

Performa SVM yang unggul dapat disebabkan oleh kemampuannya dalam membentuk hyperplane yang optimal pada ruang fitur, terutama setelah normalisasi yang menjadikan skala fitur lebih seragam.

```

=== SVM (Normalized) ===
Accuracy: 0.8120300751879699

Confusion Matrix:
[[48 19]
 [ 6 60]]

Classification Report:

```

	precision	recall	f1-score	support
0	0.89	0.72	0.79	67
1	0.76	0.91	0.83	66
accuracy			0.81	133
macro avg	0.82	0.81	0.81	133
weighted avg	0.82	0.81	0.81	133

Fig 4. *Confusion matrix* model random forest

Model K-Nearest Neighbors (KNN) menunjukkan performa terendah dibandingkan dua model lainnya dengan *accuracy* sebesar 0.7293. Berdasarkan confusion matrix, KNN lebih banyak melakukan kesalahan klasifikasi dibandingkan Random Forest dan SVM. Nilai *precision*, *recall*, dan *f1-score* berada pada kisaran 0.69–0.77.

Kinerja yang lebih rendah ini dapat disebabkan oleh sensitivitas KNN terhadap distribusi data, jarak antar data, serta pemilihan nilai *k*. Selain itu, fitur tekstur yang dihasilkan dari GLCM dan LBP mungkin memiliki variasi yang cukup kompleks sehingga sulit dipisahkan hanya dengan pendekatan berbasis kedekatan (*distance-based classifier*).

```

=== KNN ===
Accuracy: 0.7293233082706767

Confusion Matrix:
[[46 21]
 [15 51]]

Classification Report:

```

	precision	recall	f1-score	support
0	0.75	0.69	0.72	67
1	0.71	0.77	0.74	66
accuracy			0.73	133
macro avg	0.73	0.73	0.73	133
weighted avg	0.73	0.73	0.73	133

Fig 5. *Confusion matrix* model KNN

Perbandingan performa setiap model dalam pada kelas normal dapat dilihat pada tabel 1 dimana jika dilihat berdasarkan nilai presisi SVM unggul dibandingkan model lain dengan nilai presisi 89 % sedangkan performa model pada kelas tuberculosis dapat dilihat pada tabel 2. Dapat dilihat berdasarkan nilai presisi model RF unggul dibandingkan model lainnya dengan nilai presisi 79%

Tabel 1. Perbandingan performa model pada kelas normal

Model	Precision	Recal	F1 Score	Support
<i>SVM</i>	89%	72%	79%	67%
<i>RF</i>	83%	78%	80%	68%
<i>KNN</i>	75%	69%	72%	63%

Tabel 2. Perbandingan performa model pada kelas Tuberculosis

Model	Precision	Recal	F1 Score	Support
<i>SVM</i>	76%	91%	83%	66%
<i>RF</i>	79%	83%	81%	66%
<i>KNN</i>	71%	77%	74%	67%

Develop Model

Model SVM terpilih sebagai model terbaik dengan akurasi sebesar 81,2% dan digunakan sebagai basis pengembangan sistem klasifikasi penyakit tuberkulosis berdasarkan citra X-ray. Implementasi model dalam sistem rekomendasi ilustrasikan pada figure 6.

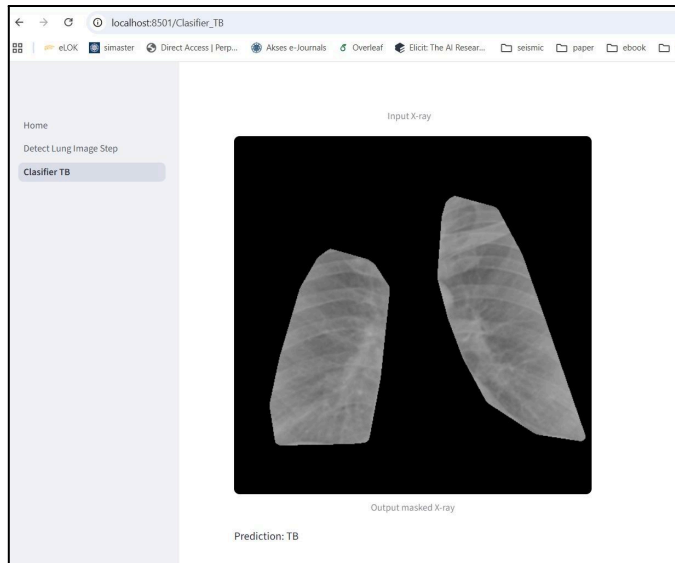


Fig 6. Implementasi model pada sistem klasifikasi penyakit tuberkulosis

V. KESIMPULAN

Penelitian ini berhasil mengembangkan sistem klasifikasi Tuberkulosis (TB) berbasis citra X-ray dada (CXR) menggunakan kombinasi *preprocessing*, segmentasi paru, ekstraksi fitur tekstur, dan algoritma pembelajaran mesin. Tahapan *preprocessing* menggunakan CLAHE dan *mean shift filtering* mampu meningkatkan kualitas citra sehingga struktur

paru lebih jelas. Segmentasi berbasis *thresholding*, kontur, dan operasi morfologi menghasilkan ROI paru yang lebih bersih dan relevan untuk analisis fitur.

Ekstraksi fitur menggunakan GLCM dan LBP terbukti efektif merepresentasikan pola tekstur yang membedakan paru normal dan paru dengan infeksi TB. Dari tiga model pembelajaran mesin yang dievaluasi, SVM dengan normalisasi memberikan performa terbaik dengan akurasi 0.812, diikuti Random Forest (0.804) dan KNN (0.729). Hasil ini menunjukkan bahwa kombinasi *preprocessing* yang tepat, segmentasi paru eksplisit, dan fitur tekstur GLCM–LBP mampu meningkatkan efektivitas klasifikasi TB pada citra CXR.

Secara keseluruhan, sistem ini memiliki potensi sebagai alat bantu diagnosis yang ringan, interpretable, dan dapat mendukung deteksi dini TB terutama di fasilitas kesehatan dengan sumber daya terbatas. Pengembangan lebih lanjut dapat dilakukan dengan memperluas variasi dataset, optimasi parameter, atau integrasi dengan pendekatan hybrid untuk meningkatkan generalisasi dan akurasi model.

REFERENSI

- [1] Global Tuberculosis Report 2024,” Oct. 29, 2024. <https://www.who.int/teams/global-programme-on-tuberculosis-and-lung-health/tb-reports/global-tuberculosis-report-2024>
- [2] “Global tuberculosis report 2024 [EN/AR/RU/ZH] - World,” ReliefWeb, Oct. 29, 2024. <https://reliefweb.int/report/world/global-tuberculosis-report-2024-enarruzh>
- [3] “Gerakan Indonesia Akhiri TBC,” Kemenkes, Apr. 11, 2025. <https://kemkes.go.id/id/indonesias-movement-to-end-tb>
- [4] Z.-L. Han et al., “A systematic review and meta-analysis of artificial intelligence software for tuberculosis diagnosis using chest X-ray imaging,” *Journal of Thoracic Disease*, vol. 17, no. 5, pp. 3223–3237, May 2025, doi: 10.21037/jtd-2025-604.
- [5] K. Pongsuwun et al., “A Systematic Review of the Accuracy of Machine learning models for diagnosing Pulmonary Tuberculosis: Implications for nursing practice and implementation,” *Nursing and Health Sciences*, vol. 27, no. 1, p. e70077, Mar. 2025, doi: 10.1111/nhs.70077
- [6] S. Hansun, A. Argha, S.-T. Liaw, B. G. Celler, and G. B. Marks, “Machine and Deep Learning for Tuberculosis Detection on Chest X-Rays: Systematic Literature review,” *Journal of Medical Internet Research*, vol. 25, p. e43154, Jul. 2023, doi: 10.2196/43154.
- [7] Getzzg, “Artificial intelligence for tuberculosis control: a scoping review of applications in public health,” *JOGH*, Aug. 04, 2025. <https://jogh.org/2025/jogh-15-04192/>
- [8] S. Cuenca-Dominguez, V. Arrobo-Sarango, D. Quinteros-Sarmiento, and F. Villalba-Meneses, “Advancing healthcare: Early tuberculosis detection in chest x-rays through select convolutional neural networks,” in *Advances in Computer Science, Electronics and Industrial Engineering (Lecture Notes in Networks and Systems)*, vol. 848. Cham: Springer, 2024, pp.

> REPLACE THIS LINE WITH YOUR MANUSCRIPT ID NUMBER (DOUBLE-CLICK HERE TO EDIT) <

- 272–284. [Online]. Available:
https://doi.org/10.1007/978-3-031-69228-4_18
- [9] A. I. Gupta, S. Dhir, A. K. Gupta, and V. Jangra, "Leveraging deep learning techniques for tuberculosis detection from x-ray images," in 2025 International Conference on Automation and Computation (AUTOCOM), Mar. 2025, pp. 1485–1491. [Online]. Available:
<https://doi.org/10.1109/AUTOCOM64127.2025.10957697>
- [10] S. M. Fati, E. M. Senan, and N. ElHakim, "Deep and hybrid learning technique for early detection of tuberculosis based on x-ray images using feature fusion," *Appl. Sci.*, vol. 12, no. 14, p. 7092, Jul. 2022. [Online]. Available: <https://doi.org/10.3390/app12147092>
- [11] K. Cao, J. Zhang, M. Huang, and T. Deng, "X-ray classification of tuberculosis based on convolutional networks," in 2021 IEEE International Conference on Artificial Intelligence and Industrial Design (AIID), May 2021, pp. 126–129. [Online]. Available: <https://doi.org/10.1109/AIID51893.2021.9456476>
- [12] I. A. Ahmed, E. M. Senan, H. S. A. Shatnawi, and M. M. A. Al-Azzam, "Multi-techniques for analyzing x-ray images for early detection and differentiation of pneumonia and tuberculosis based on hybrid features," *Diagnostics*, vol. 13, no. 4, p. 814, Feb. 2023. [Online]. Available: <https://doi.org/10.3390/diagnostics13040814>
- [13] T. Rahman et al., "Reliable Tuberculosis Detection using Chest X-ray with Deep Learning, Segmentation and Visualization," *IEEE Access*, vol. 8, pp. 191586–191601, 2020, doi: 10.1109/ACCESS.2020.3031384.